

Deteksi Transisi Respirasi Aerobik-Anaerobik Berdasarkan Respiratory Exchange Ratio (RER) Menggunakan Arsitektur Long Short-Term Memory (LSTM)

Wilson - 18223012

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Jalan Ganesha 10 Bandung
E-mail: 18223012@std.stei.itb.ac.id

Brandon Theodore Ferrinov - 18223020

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Jalan Ganesha 10 Bandung
E-mail: 18223020@std.stei.itb.ac.id

Rafli Dwi Nugraha - 18223038

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Jalan Ganesha 10 Bandung
E-mail: 18223038@std.stei.itb.ac.id

Derick Amadeus Budiono - 18223090

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung, Jalan Ganesha 10 Bandung
E-mail: 18223090@std.stei.itb.ac.id

Abstract—Pemantauan ambang batas anaerobik (Anaerobic Threshold) sangat penting untuk mengevaluasi efisiensi respirasi seluler dan dinamika produksi ATP saat tubuh mengalami peningkatan beban kerja fisik. Metode konvensional umumnya masih bergantung pada interpretasi visual pakar atau pengujian laktat darah yang bersifat invasif. Penelitian ini mengusulkan pendekatan komputasi berbasis kecerdasan buatan untuk mengotomatisasi deteksi transisi respirasi aerobik menuju anaerobik secara non-invasif menggunakan data deret waktu (time-series) fisiologis. Data eksperimen bersumber dari dataset Cardiopulmonary Exercise Testing, dengan fitur utama meliputi Detak Jantung (HR), Ventilasi Paru (VE), Konsumsi Oksigen (VO_2), dan Produksi Karbon Dioksida (VCO_2). Berdasarkan konsep biologi, pelabelan fase metabolisme diotomatisasi menggunakan indikator Respiratory Exchange Ratio (RER), di mana titik potong RER ≥ 1.0 ditetapkan sebagai kelas anaerobik. Sistem klasifikasi dibangun menggunakan arsitektur jaringan saraf Long Short-Term Memory (LSTM) yang dikombinasikan dengan teknik Sliding Window untuk menangkap ketergantungan temporal jangka panjang pada fluktuasi pernapasan. Hasil evaluasi menunjukkan bahwa model LSTM mampu memprediksi titik transisi fase respirasi seluler secara presisi, dibuktikan dengan metrik akurasi yang tinggi dan stabilitas kurva fungsi kerugian (loss) tanpa indikasi overfitting. Integrasi antara prinsip biokimia pernapasan dan pemrosesan algoritma sekuensial ini membuktikan bahwa batas kelelahan metabolik dapat dimodelkan secara akurat, memberikan landasan komputasional yang solid untuk pengembangan sistem diagnostik kebugaran otomatis.

Kata Kunci: Respirasi Seluler, Ambang Anaerobik, Respiratory Exchange Ratio, Long Short-Term Memory, Komputasi Biologi, Klasifikasi Time-Series.

I. PENDAHULUAN

A. Konsep Biologi Terkait

Respirasi seluler merupakan proses fundamental yang dilakukan oleh organisme untuk memecah molekul glukosa guna menghasilkan molekul energi Adenosine Triphosphate (ATP). Pada kondisi ketersediaan oksigen yang memadai, sel melakukan respirasi aerobik yang memproduksi ATP secara efisien (36-38 ATP per glukosa). Namun, saat tubuh mengalami hipoksia parsial akibat peningkatan beban kerja fisik, sel terpaksa beralih ke jalur respirasi anaerobik (hanya 2 ATP per glukosa) yang memicu akumulasi asam laktat. Secara makroskopis, pergeseran fase metabolisme ini dapat diamati melalui Respiratory Exchange Ratio (RER), yakni rasio antara volume produksi karbon dioksida (VCO_2) terhadap konsumsi oksigen (VO_2). Ketika sel mendominasi produksi energi secara anaerobik, nilai RER umumnya akan mencapai atau melampaui angka 1.0, menandakan subjek telah melintasi ambang batas anaerobik (Anaerobic Threshold).

B. Metode Komputasi Terkait

Penelitian ini menerapkan metode komputasi berbasis Deep Learning, secara spesifik menggunakan arsitektur jaringan saraf tiruan Long Short-Term Memory (LSTM). Berbeda dengan jaringan saraf standar, LSTM memiliki

mekanisme gerbang memori (memory gates) yang dirancang khusus untuk memproses dan mengingat urutan data deret waktu (time-series). Karakteristik ini menjadikannya sangat ideal untuk mengekstraksi ketergantungan temporal jangka panjang dari fluktuasi dinamis data VCO_2 dan VO_2 , sehingga model mampu memprediksi titik terjadinya transisi metabolisme seluler.

C. Tinjauan Pustaka Karya

Dalam literatur yang ada, penentuan ambang anaerobik sering kali masih bergantung pada metode analitik konvensional, seperti inspeksi visual pakar terhadap grafik pertukaran gas pernapasan atau pengambilan sampel laktat darah yang bersifat invasif. Beberapa penelitian terdahulu telah mencoba mengotomatisasi deteksi ini menggunakan model regresi linier maupun algoritma machine learning tradisional. Namun, pendekatan tersebut seringkali kesulitan dan mengalami penurunan akurasi ketika harus menangani fluktuasi (noise) yang tinggi serta kompleksitas sekuensial yang inheren pada data sensor biologis kardiopulmoner.

D. Rumusan Pertanyaan Penelitian

Berdasarkan latar belakang tersebut, rumusan pertanyaan penelitian pada proyek ini adalah: "Bagaimana arsitektur Long Short-Term Memory (LSTM) dapat diimplementasikan untuk mendeteksi secara otomatis dan presisi titik transisi respirasi aerobik menuju anaerobik berdasarkan metrik time-series VCO_2 dan VO_2 ?"

E. Tujuan dan Kontribusi

Tujuan dari penelitian ini adalah merancang, mengimplementasikan, dan mengevaluasi model LSTM dalam mengklasifikasikan fase produksi ATP seluler menggunakan metrik kardiopulmoner. Melalui penelitian ini, kontribusi yang diharapkan adalah tersedianya pendekatan komputasi yang objektif, non-invasif, dan otomatis untuk menganalisis efisiensi respirasi seluler akibat stres fisik. Solusi ini kedepannya berpotensi untuk diintegrasikan sebagai algoritma cerdas pada perangkat pemantauan kebugaran dan kesehatan klinis.

II. METODE

A. Metode Komputasi

Data yang digunakan merupakan data time-series, yaitu data yang memiliki urutan waktu. Oleh karena itu metode komputasi yang dipilih menggunakan model LSTM karena memiliki kemampuan untuk:

- Mengingat informasi jangka panjang
- Mengatasi masalah *vanishing gradient* pada Recurrent Neural Network (RNN)
- Memproses pola temporal dari data fisiologis
- Mendeteksi perubahan kondisi tubuh secara berurutan

Pada implementasi final.ipynb, digunakan arsitektur Bidirectional LSTM agar model memahami pola dari arah maju dan mundur.


Program menggunakan nilai Respiratory Exchange Ratio sebagai dasar klasifikasi kondisi respirasi. Nilai RER dihitung menggunakan perbandingan produksi karbon dioksida (VCO_2) dan konsumsi oksigen (VO_2). Kondisi anaerobik ditentukan ketika nilai RER lebih besar atau sama dengan 1.0, sedangkan nilai dibawah itu akan dikategorikan sebagai aerobik.

Sebelum proses training dilakukan, data dinormalisasi menggunakan metode Min-Max Scaling agar seluruh fitur yang berada pada rentang yang seragam. Selanjutnya digunakan teknik *sliding window* dengan TIME_STEPS sebesar 10 untuk membentuk sequence data time-series yang sesuai dengan kebutuhan input model LSTM.

Model deep learning dibangun menggunakan beberapa layer LSTM dan Dense layer dengan fungsi aktivasi sigmoid pada bagian output. Pada model advanced digunakan tambahan Batch Normalization, Dropout, gradient clipping, Early Stopping, dan Reduce Learning Rate untuk meningkatkan stabilitas training dan mengurangi *overfitting*.

B. Alur Kerja

Alur kerja komputasi sistem ini dirancang secara sekuensial untuk mentransformasikan data mentah sensor kardiopulmoner menjadi prediksi fase respirasi seluler yang stabil dan minim *noise*. Sebagai gambaran bagaimana alur komputasi sistem ini bekerja dijelaskan melalui flowchart dibawah



Gambar 1. Flowchart Sistem

Berdasarkan flowchart, tahapan implementasi program dieksekusi melalui urutan kronologis sebagai berikut:

1. **Akuisisi Data Mentah (Data Ingestion):** Program memuat berkas deret waktu (test_measure.csv) yang berisi rekaman sinyal biologis subjek dari pengujian beban fisik *treadmill*.
2. **Pembersihan Data (Data Cleaning):** Sensor medis sering kali menghasilkan diskontinuitas data akibat

artefak gerakan (*motion artifacts*). Program mengatasi nilai hilang (*missing values*) secara sekuensial menggunakan kombinasi teknik penyulaman maju (*forward-fill*) dan penyulaman mundur (*backward-fill*) guna menjamin kontinuitas dimensi matriks tanpa merusak dependensi temporal data.

3. **Rekayasa Fitur dan Penghalusan Sinyal (*Feature Engineering & Smoothing*):** Guna mereduksi fluktuasi frekuensi tinggi (*high-frequency noise*) pada sensor harian, program melakukan kalkulasi rata-rata bergerak (*Moving Average*) dengan ukuran jendela konstan ($\text{window}=3$) pada variabel denyut jantung (HR) dan volume ventilasi semenit (VE). Langkah ini menghasilkan fitur turunan baru yang lebih representatif, yaitu HR_MA dan VE_MA.
4. **Pelabelan Otomatis (*Ground Truth Generation*):** Sistem menghitung nilai *Respiratory Exchange Ratio* (RER) secara terisolasi pada setiap baris waktu melalui pembagian volume produksi karbon dioksida terhadap konsumsi oksigen (VCO_2/VO_2). Berdasarkan ambang batas bioenergetika, program menetapkan label biner target (*Anaerobic_Label*): nilai 1 (anaerobik) jika $\text{RER} \geq 1.0$, dan nilai 0 (aerobik) jika $\text{RER} < 1.0$.
5. **Normalisasi Skala Fitur (*Feature Scaling*):** Seluruh fitur multivariat terpilih (HR, HR_MA, VO₂, VCO₂, VE, VE_MA, Speed) ditransformasikan ke dalam rentang seragam [0, 1] menggunakan operator *Min-Max Scaler*. Hal ini krusial untuk mencegah dominasi besaran nilai (*magnitude*) dari satu variabel tertentu atas variabel lainnya saat perhitungan fungsi kerugian jaringan saraf.
6. **Segmentasi Jendela Geser (*Sliding Window Segmentation*):** Data dua dimensi ($N \times M$) dipecah dan dibentuk kembali ke dalam struktur tensor tiga dimensi ($N \times \text{TIME_STEPS} \times M$) dengan menetapkan ukuran langkah waktu $\text{TIME_STEPS} = 10$. Setiap representasi jendela sekuensial memuat data historis 10 detik ke belakang untuk memprediksi status respirasi pada detik ke-11.
7. **Pelatihan dan Evaluasi Jaringan (*Model Training & Inference*):** Tensor sekuensial diumpankan ke dalam model *Advanced Bidirectional LSTM*. Model memproses arah maju (*forward*) dan mundur (*backward*) secara simultan, melewatkannya ke lapisan *Batch Normalization* dan *Dropout* (0.3), sebelum akhirnya lapisan *Dense* dengan aktivasi *Sigmoid* menghasilkan probabilitas kontinu antara 0

hingga 1 untuk mengklasifikasikan status respirasi akhir subjek secara *real-time*.

C. Komponen yang digunakan

Fitur-fitur fisiologis utama yang diekstraksi meliputi:

- HR (Heart Rate): Denyut jantung per menit.
- HR_MA: Moving Average dari Heart Rate dengan $\text{window}=3$ untuk menghaluskan noise sensor.
- VO₂: Konsumsi volume oksigen.
- VCO₂: Produksi volume karbon dioksida.
- VE: Ventilasi semenit (Minute Ventilation).
- VE_MA: Moving Average dari metrik ventilasi dengan $\text{window}=3$.
- Speed: Kecepatan treadmill selama pengujian fisik.

```
# Ekstraksi Fitur Lanjut (Windowing)
df_subject['HR_MA'] =
df_subject['HR'].rolling(window=3,
min_periods=1).mean()
df_subject['VE_MA'] =
df_subject['VE'].rolling(window=3,
min_periods=1).mean()

features = ['HR', 'HR_MA', 'VO2', 'VCO2',
'VE', 'VE_MA', 'Speed']
data_X = df_subject[features].values
data_Y =
df_subject['Anaerobic_Label'].values
```

Penanganan data hilang dilakukan menggunakan kombinasi metode *forward-fill* (*ffill()*) dan *backward-fill* (*bfill()*) pada representasi array dua dimensi sekuensial, memastikan ketiadaan anomali matematis (NaN/Inf) sebelum pembagian data pelatihan dan pengujian.

D. Spesifikasi Model Advanced Bi-LSTM

Model deep learning dibangun menggunakan beberapa layer LSTM dan Dense layer dengan fungsi aktivasi sigmoid pada bagian output. Pada model advanced ini, ditambahkan pula Batch Normalization, Dropout, gradient clipping, Early Stopping, dan Reduce Learning Rate on Plateau untuk meningkatkan stabilitas training dan menghindari overfitting.


```
model = Sequential([
    Bidirectional(LSTM(64,
return_sequences=True),
input_shape=(X_train.shape[1],
X_train.shape[2])),
    BatchNormalization(),
    Dropout(0.3),
    Bidirectional(LSTM(32,
return_sequences=False)),
    BatchNormalization(),
    Dropout(0.3),
```

```
Dense(16, activation='relu'),
Dense(1, activation='sigmoid')
])
optimizer = Adam(learning_rate=0.001,
clipvalue=1.0)
```

III. HASIL DAN DISKUSI


A. Hasil Exploratory Data Analysis

Penelitian ini menggunakan data deret waktu (time-series) kardio pulmoner sekunder yang diekstraksi dari file `test_measure.csv`. Sebelum dilakukan pemodelan sekuensial, Exploratory Data Analysis (EDA) diterapkan pada dataset `test_measure.csv` untuk memahami distribusi, kualitas, dan karakteristik biologis dari data kardiopulmoner. Ekstraksi data difokuskan pada satu subjek tunggal guna menjaga integritas urutan waktu (time-series) dari respons fisiologis. Hasil inspeksi awal terhadap struktur data menunjukkan tidak adanya nilai yang hilang (missing values) yang signifikan pada metrik utama, sehingga proses imputasi data kompleks tidak diperlukan.



Gambar 2. Plot deret waktu dari metrik kardiopulmoner subjek uji selama protokol olahraga bertahap.

Analisis pada grafik *Speed* menunjukkan bahwa subjek contoh menjalani protokol olahraga bertahap (graded exercise testing), di mana intensitas beban kerja dinaikkan secara konstan pada interval waktu tertentu sebelum akhirnya dihentikan secara bertahap pada fase pendinginan (cool down). Peningkatan beban kerja ini berbanding lurus dengan respons kardiovaskular subjek, yang dibuktikan dari grafik HR (detak jantung) yang mengalami peningkatan linier seiring waktu, serta grafik VE (ventilasi paru) yang menunjukkan lonjakan eksponensial mendekati akhir sesi olahraga aktif. Dinamika ini mengonfirmasi kualitas data awal yang bersih dan sesuai dengan prinsip dasar respons adaptasi tubuh manusia terhadap stres fisik.




Gambar 3. Distribusi momen aerobik dan anaerobik dalam skala waktu 1000 detik

Analisis pada grafik *Speed* menunjukkan bahwa subjek menjalani protokol olahraga bertahap (graded exercise testing), di mana intensitas beban kerja dinaikkan secara konstan pada interval waktu tertentu sebelum akhirnya dihentikan secara bertahap pada fase pendinginan (cool down). Peningkatan beban kerja ini berbanding lurus dengan respons kardiovaskular subjek, yang dibuktikan dari grafik HR (detak jantung) yang mengalami peningkatan linier seiring waktu, serta grafik VE (ventilasi paru) yang menunjukkan lonjakan eksponensial mendekati akhir sesi olahraga aktif. Dinamika ini mengonfirmasi kualitas data awal yang bersih dan sesuai dengan prinsip dasar respons adaptasi tubuh manusia terhadap stres fisik.

Titik kritis pada grafik RQ yang melintasi ambang batas 1.0 merupakan penanda biologis yang esensial. Secara fisiologis, titik tersebut merepresentasikan momen ketika pasokan oksigen tidak lagi mencukupi, sehingga sel otot beralih memproduksi ATP secara anaerobik melalui jalur glikolisis. Penumpukan produk sampingan berupa asam laktat kemudian disangga oleh tubuh, menghasilkan ekskresi CO_2 ekstra yang terbaca sebagai lonjakan pada grafik RQ. Identifikasi eksplisit terhadap titik potong RQ ini pada tahap EDA memvalidasi pendekatan matematis dalam menganotasi kelas fase anaerobik (kelas 1), yang selanjutnya dinormalisasi dan direkayasa menjadi jendela sekuensial (sliding window) untuk dilatih ke dalam arsitektur jaringan LSTM.

B. Analisis Kuantitatif dan Kualitatif Performa Model


Proses pelatihan arsitektur *Bidirectional LSTM* pada data *treadmill* ini dikonfigurasi dengan ukuran *batch* sebesar 16 dan batasan maksimum 100 epoch. Guna menjamin efisiensi komputasi dan mencegah kejenuhan latih (*overfitting*), mekanisme *callback* *earlyStopping* diintegrasikan untuk memantau metrik *validation loss* secara ketat dengan parameter *patience* sebesar 10 epoch. Berdasarkan grafik konvergensi pelatihan, proses eksekusi terhenti secara otomatis pada **epoch ke-34**, di mana bobot optimal model diekstraksi dari kondisi terbaiknya pada **epoch ke-24**.



Gambar 4. Kurva Log-Loss selama pelatihan model

Secara kuantitatif, model *Advanced Bi-LSTM* yang diuji menggunakan subset data pengujian independen (proporsi *split* 80:20) mencatatkan tingkat akurasi menyeluruh (*overall accuracy*) yang baik, yakni mencapai **77%**. Evaluasi performa klasifikasi biner sekuensial secara lebih rinci dipaparkan melalui laporan klasifikasi (*classification report*) pada tabel berikut.

CLASSIFICATION REPORT MODEL BI-LSTM				
Fase/Kelas	Precision	Recall	F1-Score	Support
Aerobik	0.86	0.74	0.79	3395
Anaerobik	0.68	0.82	0.74	2277
Avg/Total	0.79	0.77	0.77	5672



Gambar 5. Hasil *Confusion Matrix* dalam prediksi

Secara kualitatif, model terbukti memiliki stabilitas generalisasi yang tinggi. Karakteristik sekuensial dari data sensor biologis kardiopulmoner berhasil dipetakan dengan halus oleh lapisan *Bidirectional LSTM* tanpa menunjukkan gejala fluktuasi prediksi (*predication toggling*) yang sering ditemui pada model *machine learning* tradisional. Model mampu membaca pola hasil pengeluaran energi dan membaca apakah seseorang berada di state aerobik atau anaerobik.

C. Analisis Hasil dalam Konteks Konsep Biologi

Hasil performa model membawa implikasi ilmiah yang sangat krusial jika ditinjau dari sudut pandang bioenergetika dan fisiologi olahraga. Nilai *precision* sebesar **0.79** pada fase aerobik (Label 0) mengindikasikan bahwa model memiliki kemampuan tinggi untuk menghindari kesalahan *False Positive*. Dalam konteks biologi pernapasan, hal ini berarti model tidak pernah salah mendiagnosis subjek telah memasuki fase respirasi anaerobik selama volume konsumsi oksigen (VO_2) masih mencukupi kebutuhan fosforilasi oksidatif di dalam mitokondria untuk memproduksi 36–38 ATP per molekul glukosa.

Sebaliknya, nilai *recall* sebesar **0.77** pada klasifikasi fase anaerobik (Label 1) membuktikan bahwa model *Bi-LSTM* berhasil menangkap **77% kejadian transisi metabolisme seluler**. Secara fisiologis, ketika intensitas latihan fisik meningkat melebihi ambang batas tertentu, laju glikolisis aerobik tidak lagi mampu mengimbangi kebutuhan ATP otot yang melonjak drastis. Sel secara instan beralih ke jalur fermentasi asam laktat (respirasi anaerob) yang memicu efek penyangga bikarbonat (*bicarbonate buffering*) untuk

menetralkan ion hidrogen (H^+). Proses kimiawi tubuh ini menghasilkan lonjakan emisi gas karbon dioksida secara masif, yang secara non-invasif tercermin dari nilai rasio pertukaran gas ($RER = VCO_2 / VO_2$) yang menyentuh angka ≥ 1.0 .

Kemampuan model dalam mengenali pola temporal dari kombinasi fitur *moving average* denyut jantung (HR_MA) dan ventilasi pernapasan (VE_MA) memungkinkan deteksi dini yang objektif tepat pada saat ambang batas anaerobik (*Anaerobic Threshold*) terlampaui. Integrasi komputasi domain spesifik ini menghilangkan ketergantungan pada metode invasif konvensional seperti penusukan jarum untuk pemantauan kadar laktat darah sekuensial, sekaligus memberikan proteksi dini bagi subjek dari risiko cedera otot akut akibat asidosis laktat.

IV. KESIMPULAN

A. Kontribusi Penelitian

Penelitian ini telah berhasil merealisasikan sebuah pendekatan komputasi domain-spesifik yang objektif dan non-invasif untuk mendeteksi transisi respirasi aerobik-anaerobik pada subjek selama latihan fisik sekuensial. Melalui pemanfaatan arsitektur *Advanced Bidirectional Long Short-Term Memory* (Bi-LSTM), karakteristik temporal dari metrik kardiopulmoner berhasil dipetakan dengan tingkat akurasi akhir mencapai 77%.

Kontribusi utama dari penelitian ini terletak pada otomatisasi penentuan Ambang Batas Anaerobik (*Anaerobic Threshold*) berdasarkan nilai ambang fisiologis *Respiratory Exchange Ratio* ($RER \geq 1.0$) tanpa bergantung pada inspeksi visual manual yang bersifat subjektif atau protokol klinis konvensional yang bersifat invasif (seperti pengambilan sampel laktat darah berkala). Kemampuan model dalam mencatatkan nilai *precision* baik (0.79) pada fase aerobik beserta *recall* baik (0.77) pada fase anaerobik membuktikan keandalan model ini sebagai sistem deteksi dini. Pendekatan komputasi ini memberikan landasan teoritis dan praktis yang kuat untuk diintegrasikan ke dalam algoritma cerdas pada perangkat pemantauan kesehatan serta kebugaran real-time (*wearable devices*).

B. Saran untuk Penelitian di Masa Depan

Meskipun model yang dikembangkan menunjukkan performa klasifikasi yang sangat superior, terdapat beberapa

ruang pengembangan yang esensial untuk penelitian selanjutnya:

1. **Eksansi dan Diversifikasi Dataset:** Penelitian masa depan disarankan untuk menguji dan melatih model menggunakan basis data yang lebih heterogen, mencakup variasi subjek berdasarkan rentang usia, jenis kelamin, tingkat kebugaran dasar (atlet vs. non-atlet), serta kondisi medis tertentu untuk meningkatkan kemampuan generalisasi model (*cross-subject generalization*).
2. **Eksplorasi Arsitektur Model Lanjut:** Perlu dilakukan eksperimen komparatif menggunakan arsitektur mutakhir berbasis mekanisme atensi seperti *Transformer-based time-series models* atau kombinasi *Convolutional Neural Network* dan LSTM (CNN-LSTM) guna mengeksplorasi efisiensi ekstraksi fitur spasial sekaligus temporal secara simultan.
3. **Uji Coba Implementasi Edge Computing:** Disarankan untuk melakukan optimasi model melalui teknik kuantisasi (*model quantization*) atau pemangkasan bobot (*pruning*) agar model Bi-LSTM yang ringkas dapat ditanamkan langsung (*embedded*) pada mikrokontroler perangkat *wearable*, sehingga komputasi deteksi transisi respirasi seluler dapat berjalan sepenuhnya di sisi lokal (*edge computing*) dengan konsumsi daya yang rendah.

REFERENSI

- [1] D. Mongin, JG. Romero, and JRA. Cruz, "Treadmill Maximal Exercise Tests from the Exercise Physiology and Human Performance Lab of the University of Malaga", Dec. 10, 2021. (references) <https://physionet.org/content/treadmill-exercise-cardioresp/1.0.1/>
- [2] GeeksForGeeks, "Introduction to Long Short Term Memory", May. 18, 2026 <https://www.geeksforgeeks.org/deep-learning/deep-learning-introduction-to-long-short-term-memory/>
- [3] "The process of aerobic respiration", <https://www.monash.edu/student-academic-success/biology/cellular-respiration/the-process-of-aerobic-respiration>

LAMPIRAN

Video Demo Kode :

<https://youtu.be/IyXNbuIuc7A?si=UOLiLGOYCw54odlX>

GitHub:

<https://github.com/DerickAmadeus/KDS-Kelompok12>

GitHub Release:

<https://github.com/DerickAmadeus/KDS-Kelompok12/releases/tag/V1.0>